

#### Processus ETL

La société Northwind



Réalisé par Arroud Yassir

## **Objectif du projet:**

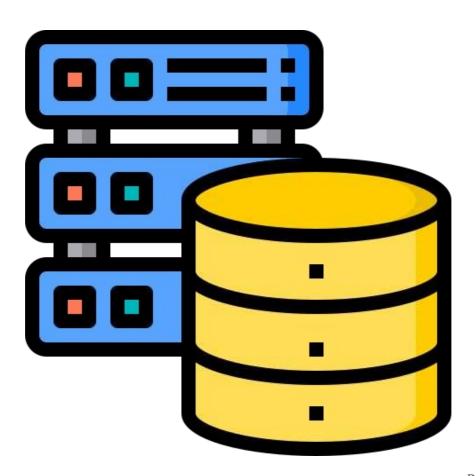
Implémenter le processus ETL à partir d'un ensemble de fichiers de différents types et d'une BD opérationnelle, afin de charger un DW complet en exploitant les requêtes d' SQL analytique.

### Table des matières:

1 Notions et définitions	3
2 Préparation de l'environnement 5	5
3 Le projet3	

## 1) Notions et définitions :

Une base de données (que nous nommerons BDD par commodité) est une collection d'informations organisées afin d'être facilement consultables, gérables et mises à jour. Au sein d'une database, les données sont organisées en lignes, colonnes et tableaux. Elles sont indexées afin de pouvoir facilement trouver les informations recherchées à l'aide d'un logiciel informatique. Chaque fois que de nouvelles informations sont ajoutées, les données sont mises à jour, et éventuellement supprimées.



## 1) Notions et définitions :

- Le Data Warehouse(DW), ou entrepôt de données est une base de données permettant de délivrer des données dans le but de l'analyse et du reporting
- Il est définit par ses fonctions :
- ☐ Contenu: Stocker des données de qualité, intégrées et historiques. Principe du «single version of the Truth»

## ☐ Usage:

- Restituer efficacement des données facile à comprendre et à explorer
- Être capable de s'adapter aux changements et évolutions des besoins utilisateurs en terme d'analyse
- Gérer les accès: assurer l'accès à la bonne donnée par la bonne personne

## 1) Notions et définitions :

ETL est un acronyme qui désigne les termes "

Extract Transform Load ". Il s'agit d'un type de logiciel permettant de collecter des données en provenance de sources multiples pour ensuite les convertir dans un format adapté à une Data Warehouse et les y transférer



## 2) Préparation de l'environnement :

## 1) SSMS:



SSMS ou (SQL server management studio) est l'outil multilingue de gestion des bases de données de Microsoft <u>SQL Server</u> et permet l'interaction entre le code <u>SQL</u> nécessaire à la manipulation des bases de données par les développeurs, comme à la gestion par les <u>administrateurs de bases de données</u> des différentes instances SQL Server.

**SQL Server Integration Services** (**SSIS**) est un composant du logiciel de base de données <u>Microsoft SQL Server</u> qui peut être utilisé pour effectuer un large éventail de tâches de <u>migration</u> de <u>données</u>.

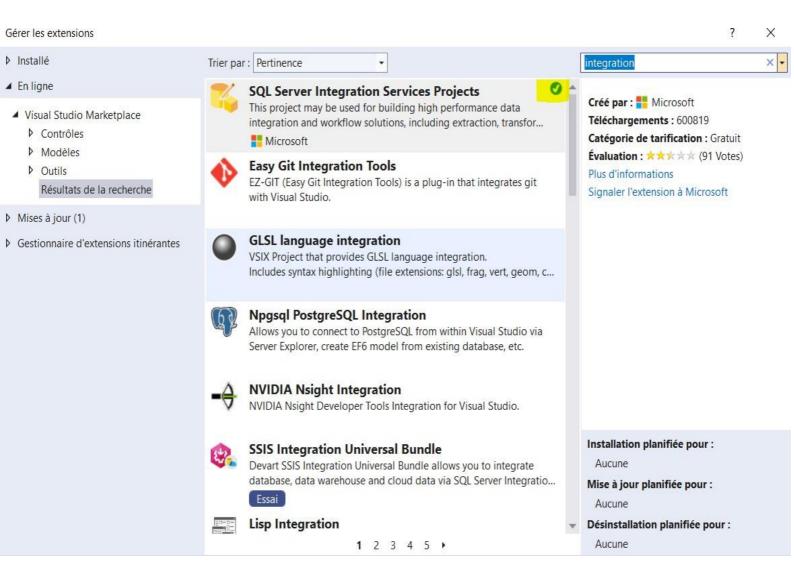
SSIS est une plate-forme pour l'intégration de données et les applications de flux de travail.

## 2) Préparation de l'environnement :

## 2.2) SSIS:



Il comporte un outil d'entreposage de données utilisé pour l'extraction la transformation et le chargement des données. L'outil peut également être utilisé pour automatiser la maintenance des bases de données SQL Server et les mises à jour des données de cube multidimensionnelles.



## 2) Préparation de l'environnement :

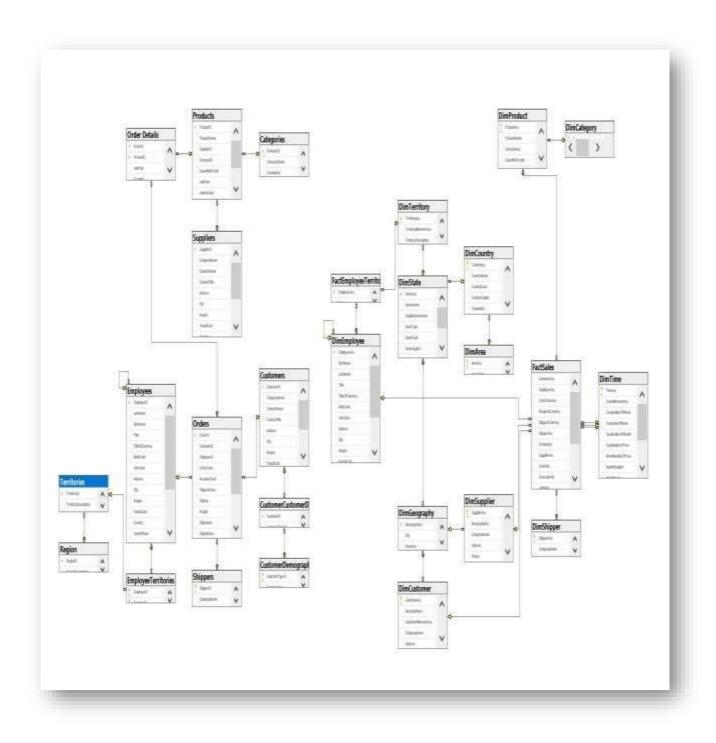
## 2.3) Visual Studio:



Microsoft Visual Studio est une suite de logiciels de développement pour Windows et mac OS conçue par Microsoft.

## 3) Le projet :

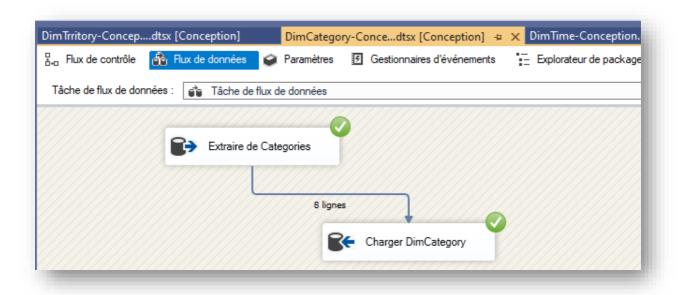
D'abord, on a commencé par la création des deux bases Northwind DB et Northwind DW en exécutant les fichiers NorthwindDB.sql et NorthwindDW.sql dans l'outil SSMS



On remarque que les tables de la Base de données (NorthwindDB) sont remplies tandis que les tables du DataWarehouse (NorthwindDW) sont vides. C'est en effet le but de notre projet ,on va remplir le DW à laide du processus ETL.

On doit appliquer ce processus à chaque dimension ;pour cela on a commencé par le chargement de notre première dimension DimCategory.

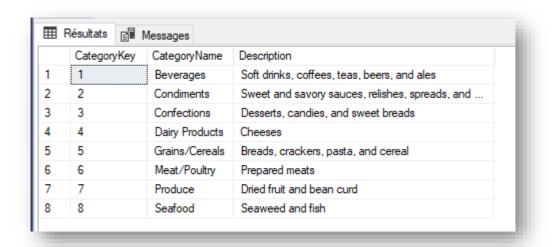
En utilisant les liens existants dans Visual Studio on a fait l'extraction des données de la table Categories qui se trouve dans le fichier NorthwindDB.sql et on les charges dans la dimension DimCategory



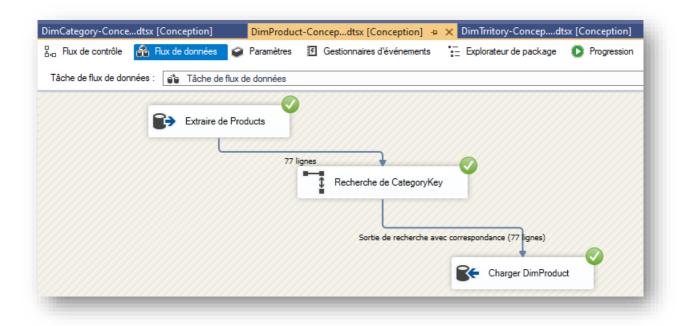
#### Dans SSMS et en tapant la requête de SQL Analytique

select \* from DimCategory

On a visualisé notre table comme affiché ci-dessous

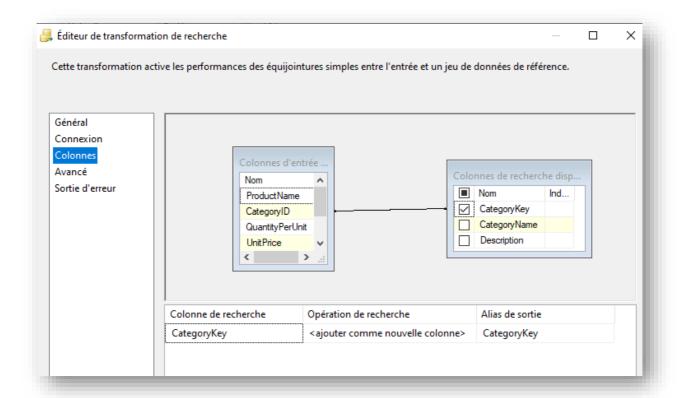


on doit maintenant appliquer le l'ETL à la table DimProduct



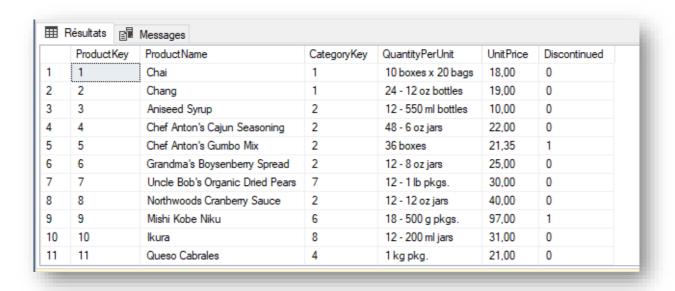
Dans cette dimension on a ajouté la partie de la recherche ,après l'extraction des données de la table Products de la Base de données Northwind DB, on a constaté que la colonne CategoryKey n'a pas le même attribut que la table départ

C'est pourquoi on a pensé à faire le mappage CategoryID et CategoryKey afin de Rechercher la colonne CategoryKey dans la table DimCategory

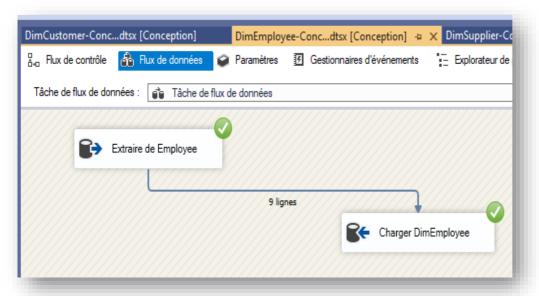


On a affiché les données de la table DimProduct

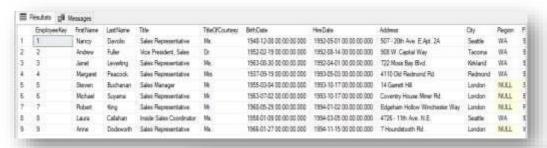
#### select \* from DimProduct



#### Après on a rempli les deux tables DimEmployee et DimShipper



#### select \* from DimEmployee





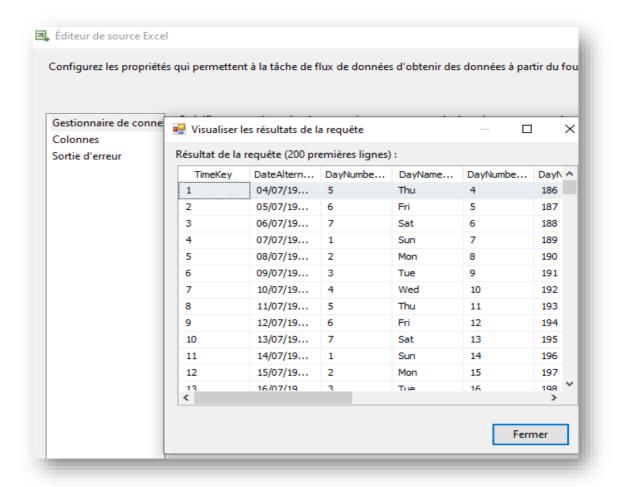
select \* from DimShipper

	ShipperKey	CompanyName	Phone
1	1	Speedy Express	(503) 555-9831
2	2	United Package	(503) 555-3199
3	3	Federal Shipping	(503) 555-9931

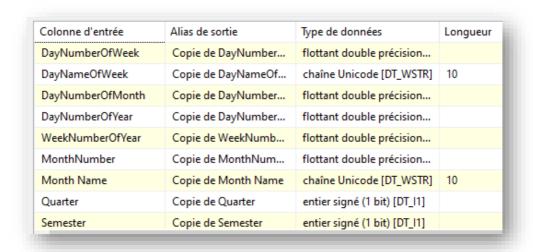
PAGE 13

#### Le Chargement de DimTime:

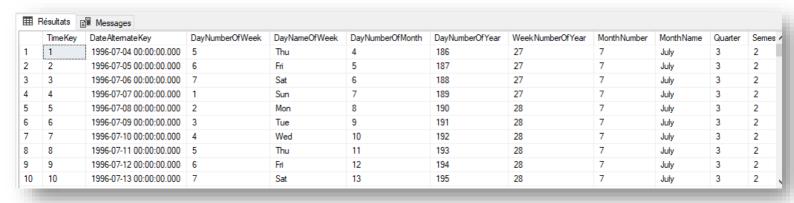
On a commencé par la préparation d notre fichier Excel qui va contenir les données (vous le trouverez en pièce jointe) après on a fait l'extraction des données de notre fichier Excel Time

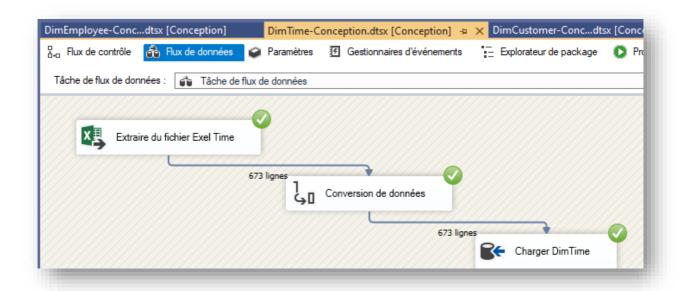


#### On a ensuite convertit nos données extraites

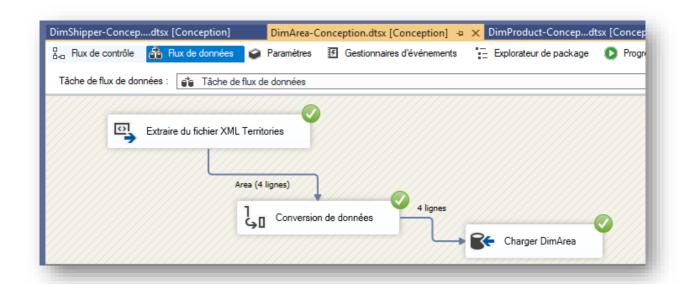


# Voici un aperçu de la table DimTime après l'exécution du flux ETL : select \* from DimTime

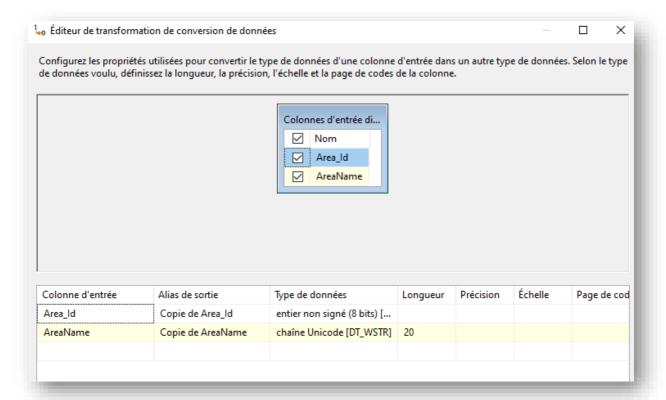




#### Chargement de DimArea

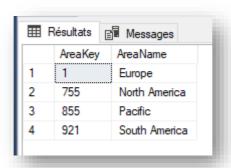


on a fait l'extraction a partir du fichier Territories.xml puis on a fait la conversion des données afin de régler la longueur des chaines de caractères dans les colonnes (AreaName est fixée à une longueur de 20)



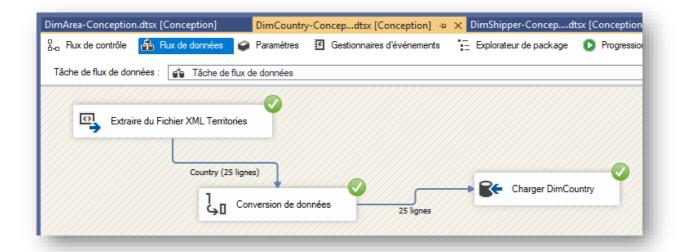
#### On a affiché nos données

select \* from DimArea



On a appliqué les mêmes étapes et on a fait la conversion des données aussi des deux dimensions DimCountry DimState qu'on a extrait du fichier XML

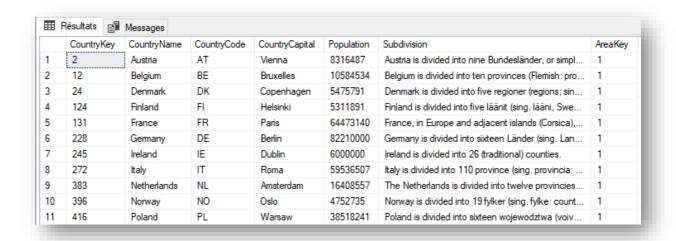
#### **Chargement de DimCountry:**



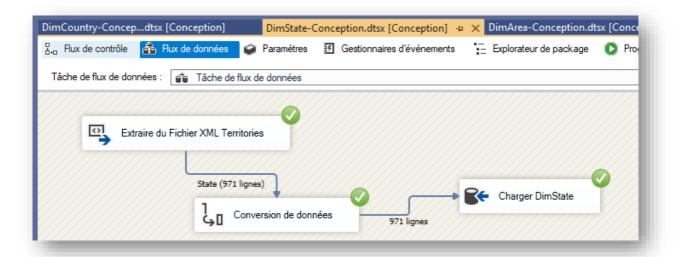
#### La conversion:

Colonne d'entrée	Alias de sortie	Type de données	Longueur
Country_ld	Copie de Country_ld	entier non signé (8 bits) [	
CountryName	Copie de CountryName	chaîne Unicode [DT_WSTR]	40
CountryCode	Copie de CountryCode	chaîne Unicode [DT_WSTR]	3
CountryCapital	Copie de CountryCapi	chaîne Unicode [DT_WSTR]	40
Population	Copie de Population	entier non signé (4 bits) [	
Subdivision	Copie de Subdivision	flux de texte Unicode [DT	
Area_ld	Copie de Area_ld	entier non signé (8 bits) [	

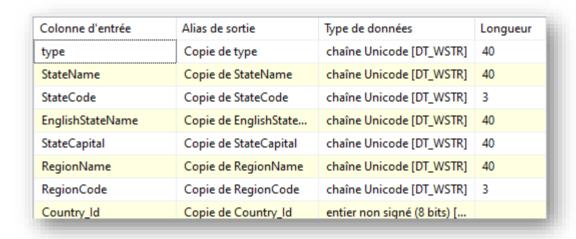
select \* from DimCountry



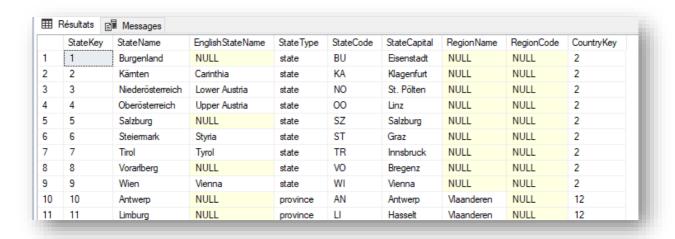
#### **Chargement de DimState:**



#### La conversion:

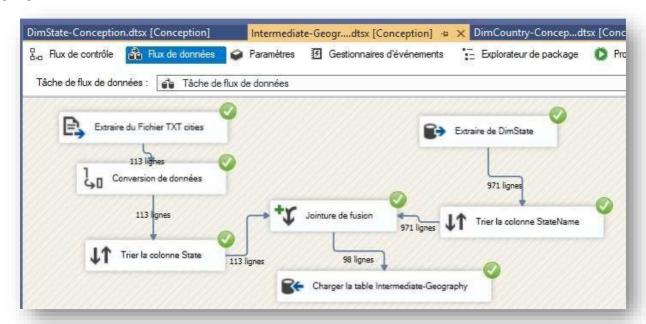


select \* from DimState



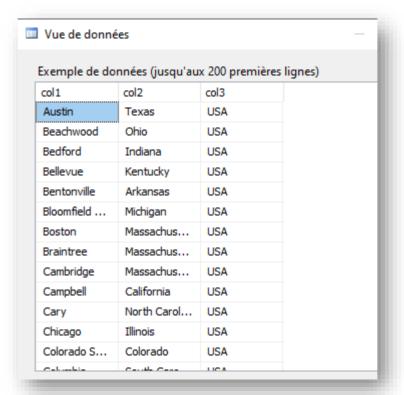
#### **DimGeography:**

On a commencee par la creation d'une table intermédiaire grâce au flux suivant :

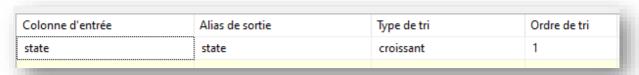


L'extraction se fait du fichier texte Cities.txt. Voici un aperçu des colonnes de

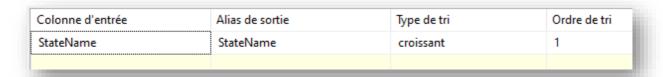
ce fichier:



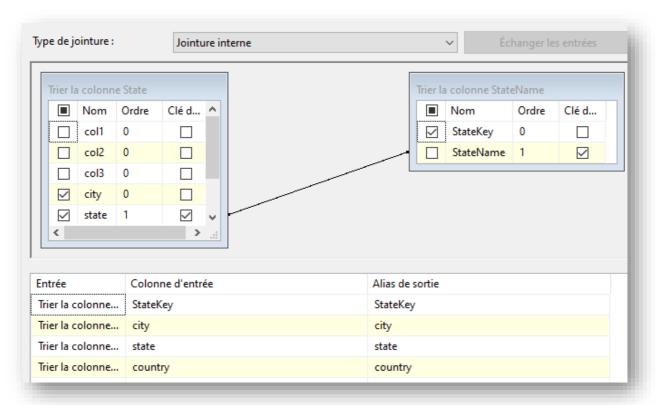
On a aussi utilisee les colonnes de la table DimState : On va extraire les 2 colonnes StateKey (pour remplire la table DimGeography) et StateName (Colonne utilisée pour la jointure).



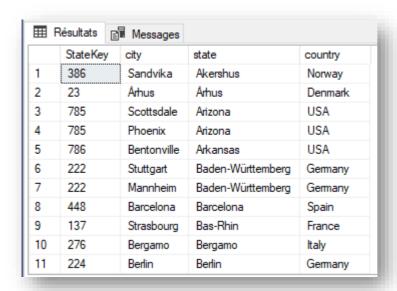
Le tri nous a permis de trier les colonnes de jointure (Colonne 1 pour le fichier texte et la colonne StateName pour DimState).



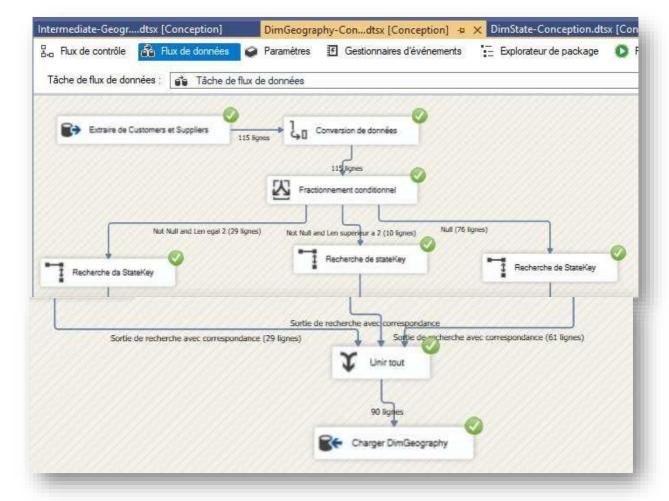
La jointure :On fait la jointure entre les 2 sources en utilisant StateName-Colonne O. Après la jointure, on va obtenir un tableau contenant les colonnes : State – KeyState – City – Country



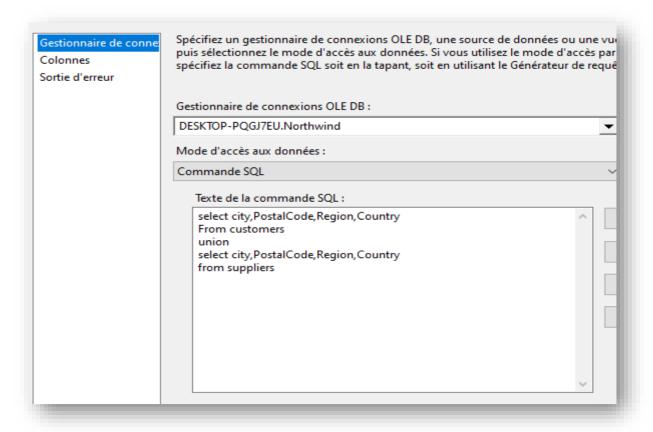
Voici un aperçu de la table intermédiaire :



Après avoir chargé la table intermédiaire, nous allons créer le flux qui charger la table DimGeography :



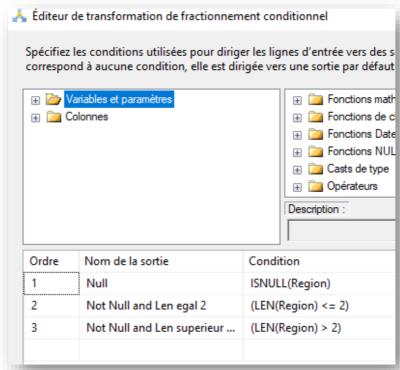
Extraire les colonnes City, PostalCode, Region et Country + L'union des lignes des tables de Customer et Supplier .



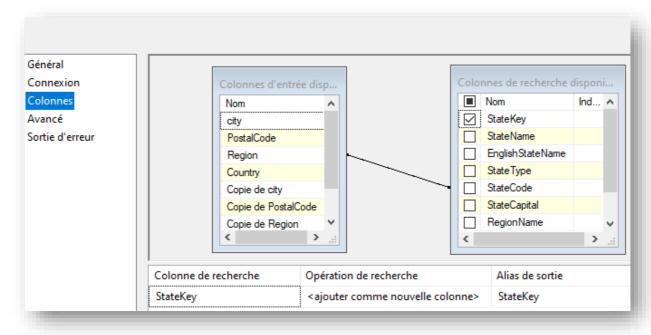
Conversion de données:

Colonne d'entrée	Alias de sortie	Type de données	Longueur	P
city	Copie de city	chaîne [DT_STR]	40	
PostalCode	Copie de PostalCode	chaîne Unicode [DT_WSTR]	40	
Region	Copie de Region	chaîne Unicode [DT_WSTR]	40	
Country	Copie de Country	chaîne Unicode [DT_WSTR]	40	

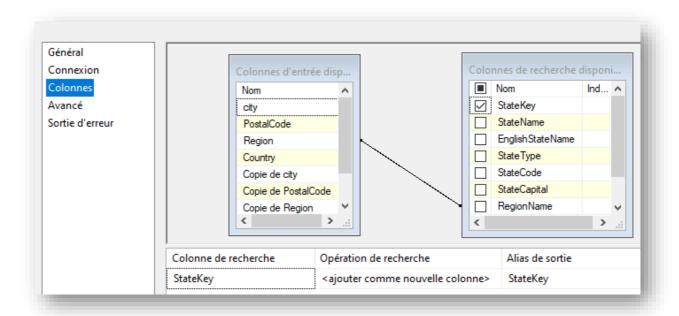
Le Fractionnement Conditionnel :Nous allons faire un fractionnement conditionnel des 3 types de lignes afin que chacune soit traitée de la manière convenable



Lignes dont len(Region)<=2 (Qui contiennent StateCode)
Rechercher: On fera le mappage entre Region (qui contient stateCode)
des tables Customers/suppliers et StateCode de la table DimState afin de
trouver StateKey.

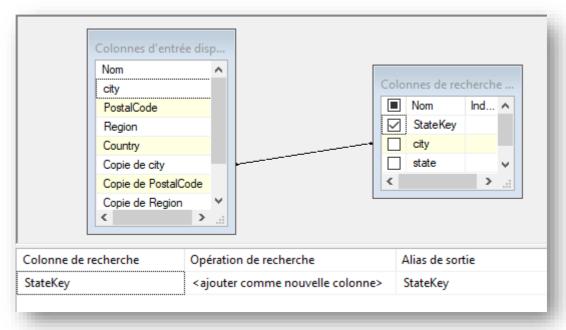


Lignes dont len(Region)>2 (Qui contiennent StateName) Rechercher: On fera le mappage entre Region (qui contient StateCode) des tables Customers/suppliers et StateName et StateName de la table DimState afin de trouver StateKey.



Lignes dont region contient la valeur NULL

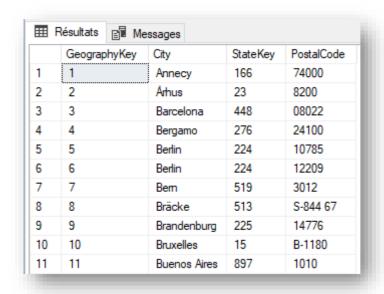
Rechercher: On fera le mappage entre les colonnes City de la table Suppliers/customers et City de la table intermédiaire créée et qui contient StateKey. Comme ça on pourra trouver StateKey demandée.



Unir tout : Après on fera l'union de l'ensemble des lignes qui étaient séparées après avoir fait la recherche.

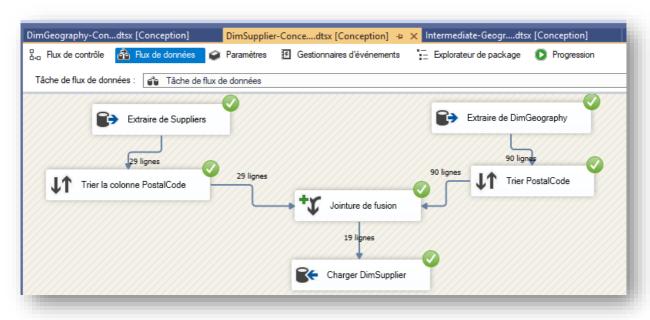
Source OLE DB : afin de charger les colonnes de DimGeography. Voici un aperçu de la table DimGeography après

avoir exécuté le flux :

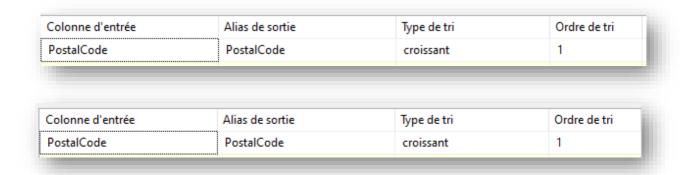


Pour répondre à la dernière requête on doit compléter les dimensions qui restent;

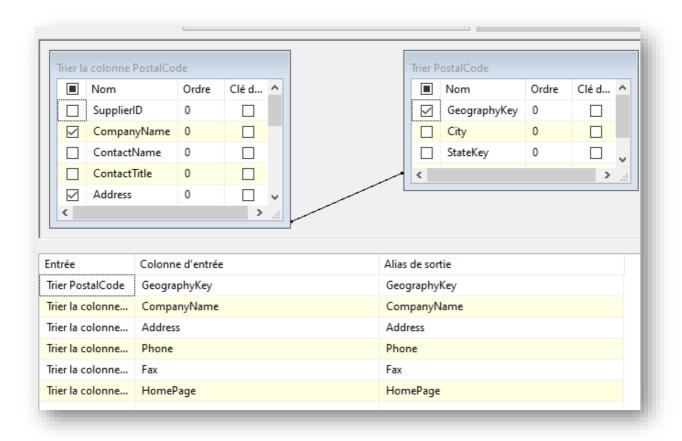
#### **Chargement de DimSupplier:**



Extraction des colonnes des tables Suppliers et DimGeography On a trié les colonnes PostalCode des 2 tables qui seront utilisées dans la jointure



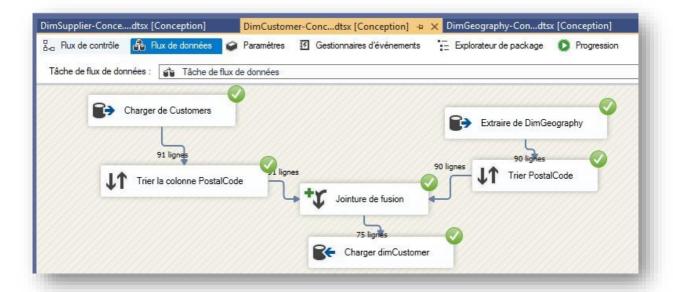
On a fait une jointure entre les 2 tables et extraire les colonnes GeographyKey – CompanyName – Adress- Phone – Fax – HomePage



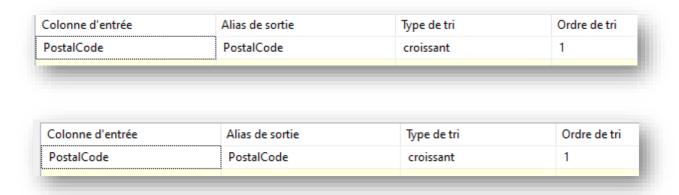
#### select \* from DimSupplier

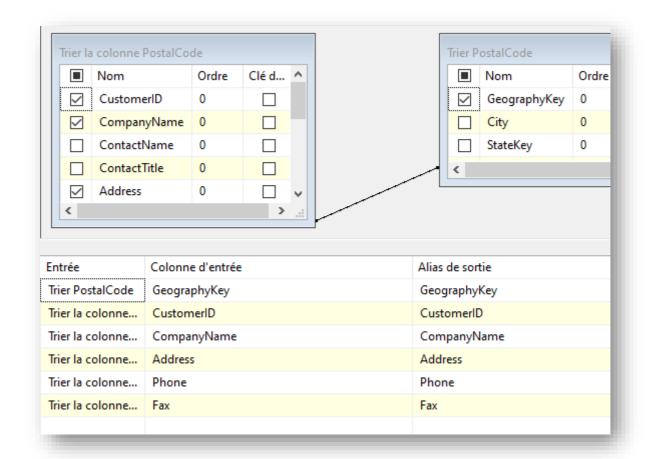


#### **Chargement de DimCustomer:**

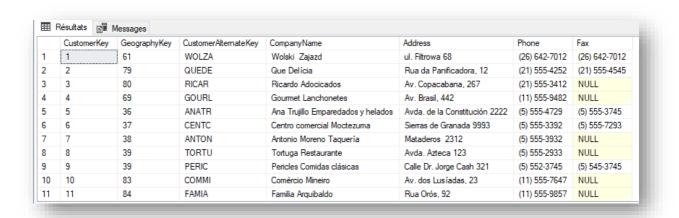


on a créé 2 Sources OLE DB afin d'extraire les colonnes des deux tables Customers et DimGeography, après on trie la colonne qui sera utilisée dans la jointure PostalCode

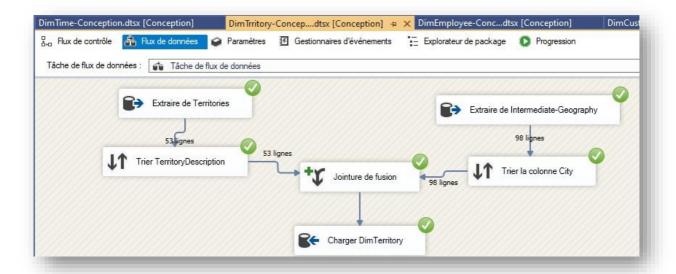




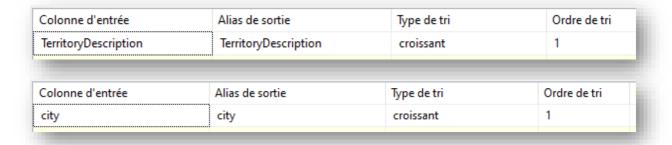
#### select \* from DimCustomer



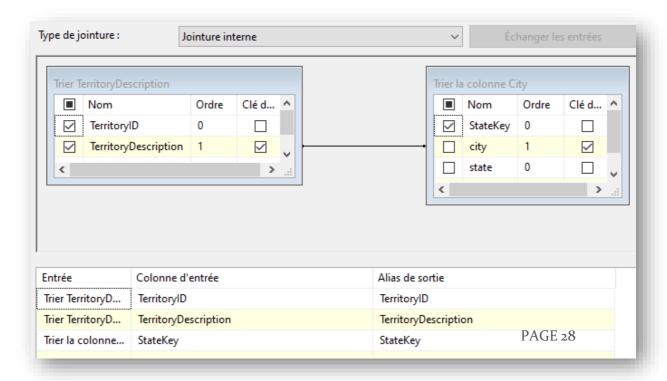
#### **Chargement de DimTerritory:**



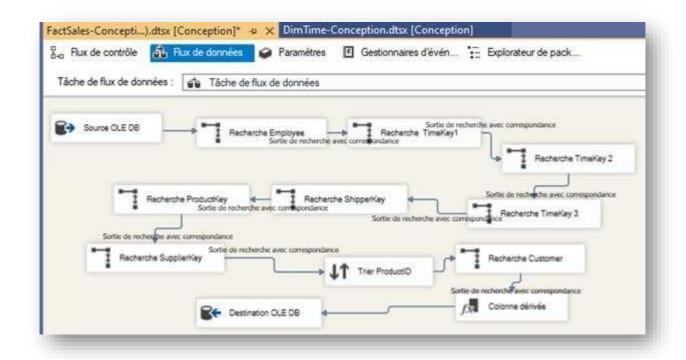
La table intermédiaire contient la colonne City et la table Territories contient la colonne TerritoryDescription (les noms des villes). On triera ces 2 colonnes tirées



#### La jointure



#### Et finalement on va remplir la table centrale FactSales



Recherche: Afin de trouver la colonne EmployeeKey

3 Recherches: Afin de trouver la colonne TimeKey. Pour les 3 recherches, on fera les mappages respectifs: DateAlternateKey-OrderDate, DateAlternateKey-ShippedDate,

DateAlternateKeyRequiredDate

Recherche Shipper: Afin de trouver ShipperKey

Recherche Product : Afin de trouver ProductKey

Recherche Supplier: Afin de trouver SupplierKey

Trier : Afin de trier par ordre croissant ProductID comme demandé dans l'énoncé.

Recherche Customer: Afin de trouver CustomerKey

Colonne dérivée : Afin de créer la colonne SalesAmount qui sera calculée à partir des colonnes UnitPrice, Quantity, Discount.

